TECH CHALLENGE - FASE 2

Predição IBOVESPA

Data Analytics & Machine Learning

Integrantes: Giovanna Silva, Hyago Miranda, Danyllo Estevão, Lucas Andrade e Lívia Hanashiro

01. Introdução

Fundamentação e Coleta de Dados

OBJETIVO

No mercado financeiro, tomar decisões rápidas e bem informadas faz toda a diferença. Pensando nisso, nosso objetivo é desenvolver um modelo preditivo capaz de indicar se o IBOVESPA vai subir ou cair no dia seguinte.

A proposta é simples: usando apenas dados históricos do próprio índice, o modelo aprende padrões do mercado e gera uma previsão de tendência — alta (↑) ou baixa (↓). Essa previsão será utilizada para apoiar analistas quantitativos na tomada de decisão, por meio de dashboards internos.

Para garantir que o modelo seja realmente útil na prática, estabelecemos uma meta clara: atingir pelo menos 75% de acurácia nas previsões em dados de teste

COLETA DE DADOS

O pipeline iniciou com a extração de dados diários do IBOVESPA diretamente de fontes públicas, focando no arquivo **ibovespa_tratado.csv**.
Utilizamos um horizonte temporal histórico para capturar ciclos de volatilidade, garantindo que o modelo aprenda padrões de mercado em diferentes cenários econômicos.
Ações principais: Conversão de DateTime, ordenação cronológica e verificação de integridade dos campos Open, High, Low e Close.

02. Preparação da Base

Definição do Alvo e Janelas

TARGET E JANELA DE TESTE

Definição do Target

Target Binário (Amanhã > Hoje).
Remoção rigorosa de nulos (NaN) gerados pelos indicadores técnicos.

Divisão de Dados

Treino: Histórico Total
Teste: Últimos 30 dias (Último mês)

Esta divisão respeita o fluxo temporal exigido pelo projeto Pos Tech.

03. Escolha do Modelo

Justificativa da Arquitetura

RANDOM FOREST CLASSIFIER

Por que Árvores?

O modelo Random Forest foi escolhido por sua robustez contra outliers e capacidade de capturar interações não lineares complexas entre indicadores técnicos ruidosos.

Hiperparâmetros

Utilizamos **250 estimadores** com profundidade máxima (max_depth) de **5** para equilibrar o aprendizado e evitar o overfitting.

04. Modelo de Otimização

Threshold

OTIMIZAÇÃO DE THRESHOLD

O threshold é justamente o valor usado para transformar essa probabilidade em uma decisão de alta ou baixa.

A curva demonstra como o ajuste fino da probabilidade permitiu atingir o patamar acima de 75%.

05. Engenharia de Atributos

Sinais Técnicos de Reversão

INDICADORES ESTRATÉGICOS

Williams R & Stochastic

Implementação de **%K** e **%R** para identificar zonas de exaustão e sobrecompra/sobrevenda.

Força Relativa (RSI)

Cálculo de momentum em 14 períodos para medir a velocidade e mudança dos movimentos de preço.

Distância EMA

Medição do afastamento do preço em relação à Média Móvel Exponencial (EMA 5) para detectar retrações.

06. Resultados e Análise

Desempenho e Confiança

RESUMO DO RESULTADO

76.7%

Acurácia em Teste

Objetivo Atingido:

O modelo superou a meta de 75% exigida pelo Tech Challenge, demonstrando alta confiabilidade em dados inéditos (out-of-sample).

- ✓ Precision Alta: **0.78**
- ✓ Recall Alta: **0.82**

MÉTRICAS E CONFIANÇA

Classe	Precision	Recall	F1-Score	Support
Baixa (0)	0.75	0.69	0.72	13
Alta (1)	0.78	0.82	0.80	17
Acurácia Final	-	-	**76.67%**	**30**

O modelo se mostrou especialmente forte em identificar dias de Alta (Classe 1), com um F1-Score de 0.80.

JUSTIFICATIVA TÉCNICA FINAL

- **Natureza Sequencial:** O modelo foi treinado exclusivamente com dados "Lagged". Isso significa que as decisões de hoje usam apenas informações conhecidas até ontem, eliminando qualquer risco de *Look-ahead Bias*.
- **Overfitting vs Generalização:** A escolha de um *max_depth=5* foi vital. Uma profundidade maior aumentaria a acurácia de treino, mas degradaria a performance nos 30 dias de teste. Nosso foco foi a robustez real em produção.
- **Tratamento de Pesos:** Utilizamos *class_weight='balanced_subsample'* para assegurar que o modelo não fosse tendencioso para uma classe específica em períodos de tendência forte.

Conclusão

O modelo é robusto, confiável e está pronto para alimentar dashboards internos de tomada de decisão. A acurácia de **76.7%** garante uma vantagem estatística significativa para o fundo de investimentos.

Obrigadx!